Relatório Inteligência Artificial

Universidade Federal de São João Del Rei

Profa. DSc. Érica C.R. Carvalho

Proposta

Segmentação de Clientes de Cartão de Crédito com Aprendizado Não Supervisionado

---

Integrantes

Igor Luis Galo - Yuri Codreanski Collinett Guimarães - Rafael Shivaom Gonçalves Rodrigues - Vinícius de Paiva Leles

Sumário

1. Introdução ao Problema **3**

a. Contextualização 3

b. Objetivo 3

2. Fundamentação Teórica **3**

a. Aprendizagem Não Supervisionada 3

b. K - Means 4

c. PCA 4

3. Metodologia (Coleta e Pré-Processamento) **4**

a. Os Dados Utilizados 5

b. Tratamento dos Dados 5

c. Transformação dos Dados 6

4. Descrição do Modelo Utilizado **8**

a. Justificativa do K-Means 8

b. Escolha do Parâmetro 8

5. Resultados e Análise **9**

a. Apresentação Visual 9

b. Interpretação dos Clusters 10

c. Mapa de Calor 11

6. Considerações Finais **12**

a. Conclusões 12

b. Desafios 12

c. Trabalhos Futuros 12

7. Referências **13**

1. Introdução ao Problema

a. Contextualização

O projeto aborda o problema de segmentação comportamental de clientes de cartão de crédito utilizando técnicas de Aprendizado de Máquina Não Supervisionado (*Clustering*).

b. Objetivo

O trabalho traz como objetivo identificar agrupamentos naturais em bases de dados de clientes (analisando fatores como hábitos de consumo, endividamento e liquidação substancialmente distintos, etc.) sem a necessidade de rotulação prévia possibilita:

- Concessão de limites de crédito proporcional ao risco do usuário;
- Campanhas de marketing e benefícios direcionados (ex.: recompensas por compras pontuais vs. incentivo a parcelamentos);
- Identificação precoce de comportamento de risco (ex.: dependência de saques rotativos e pagamento mínimo de faturas);
- Ações de retenção para clientes de alta renda e uso frequente.

2. Fundamentação Teórica

a. Aprendizagem Não Supervisionada

O aprendizado não supervisionado, também conhecido como aprendizado de máquina não supervisionado, utiliza algoritmos de aprendizado de máquina (ML) para analisar e agrupar conjuntos de dados sem rótulos. Esses algoritmos descobrem padrões ocultos ou agrupamentos de dados sem a necessidade de intervenção humana.

O modelo de aprendizado em questão é utilizado em três abordagens principais: *Clustering* (agrupamento de dados, presente na implementação do trabalho); associação e redução de dimensionalidade.

b. K - Means

O agrupamento k-means é um algoritmo de aprendizado não supervisionado utilizado para agrupamento de dados, reunindo pontos de dados não rotulados em grupos ou clusters.

Caracterizando-se como um algoritmo eficiente, eficaz e simples, o K-Means é baseado em centróides iterativos, que divide um conjunto de dados em grupos semelhantes com base na distância entre seus centróides. O centróide, ou centro do cluster, é a média ou a mediana de todos os pontos dentro do cluster, dependendo diretamente das características dos dados.

c. PCA

A análise de componentes principais (PCA - *Principal component analysis*) é uma técnica estatística não supervisionada que reduz o número de dimensões em grandes conjuntos de dados, transformando variáveis potencialmente correlacionadas em um conjunto menor de variáveis linearmente não correlacionadas, projetando os dados para reter a maior variância possível.

O método é muito eficaz para visualizar e explorar conjuntos de dados de alta dimensão ou dados com muitos atributos, pois pode identificar facilmente tendências, padrões ou valores discrepantes. Sendo comumente usado para pré-processamento de dados para uso com algoritmos de aprendizado de máquina, ele pode extrair os atributos mais informativos de grandes conjuntos de dados, simultaneamente preservando as informações mais relevantes do conjunto de dados inicial. Portanto, reduzindo a complexidade do modelo, pois a adição de cada novo atributo impacta negativamente o desempenho do modelo, o que é comumente chamado de "maldição da dimensionalidade".

3. Metodologia (Coleta e Pré-Processamento)

a. Os Dados Utilizados

Para o desenvolvimento do projeto, foi utilizado o conjunto de dados *Credit Card Dataset for Clustering*, disponibilizado na plataforma Kaggle.

A base de dados é composta originalmente por 8.950 registros de clientes e 18 colunas, sendo uma coluna de identificação e outras 17 variáveis numéricas relacionadas ao comportamento financeiro dos usuários. Os dados contemplam informações referentes a um período de seis meses de utilização dos cartões de crédito.

Entre os principais atributos presentes na base, destacam-se:

- **BALANCE**: saldo devedor remanescente na conta do cliente;
- **PURCHASES**: volume financeiro total de compras realizadas;
- **ONEOFF_PURCHASES** e **INSTALLMENTS_PURCHASES**: valores referentes às compras à vista e parceladas;
- **CASH_ADVANCE**: volume financeiro utilizado em adiantamentos de dinheiro;
- **PURCHASES_FREQUENCY**: frequência de realização de compras;
- **CREDIT_LIMIT**: limite de crédito concedido ao cliente;
- **PAYMENTS**: valor total pago pelo cliente;
- **MINIMUM_PAYMENTS**: valor mínimo de pagamento registrado;
- **PRC_FULL_PAYMENT**: percentual de meses em que a fatura foi integralmente quitada;
- **TENURE**: tempo de utilização do cartão, em meses.

Essas variáveis permitem analisar diferentes aspectos do comportamento financeiro dos clientes, como hábitos de consumo, utilização do limite de crédito, frequência de compras e

comportamento de pagamento. Dessa maneira, a base fornece informações relevantes para a identificação de padrões e a formação de grupos de clientes com características semelhantes.

b. Tratamento dos Dados

Inicialmente, foi realizada a leitura da base de dados utilizando a biblioteca Pandas, em Python, seguida de uma análise de sua estrutura e dos atributos disponíveis.

Durante essa etapa, identificou-se que a coluna **CUST_ID** correspondia exclusivamente ao identificador individual de cada cliente, não possuindo informações relacionadas ao seu comportamento financeiro. Por esse motivo, a coluna foi removida, uma vez que sua permanência poderia interferir nos cálculos de distância utilizados pelo algoritmo de agrupamento.

Após essa remoção, a base passou a apresentar 17 atributos numéricos, que foram mantidos para as etapas seguintes do processamento.

Em seguida, foi realizada a identificação de valores ausentes (*missing values*). Foram encontrados registros sem informação nas variáveis **CREDIT_LIMIT**, com 1 ocorrência, e **MINIMUM_PAYMENTS**, com 313 ocorrências.

Para solucionar esse problema, foi aplicada a imputação pela mediana de cada respectiva variável. Essa escolha foi adotada porque os atributos financeiros apresentam distribuições assimétricas e valores discrepantes (*outliers*), situações nas quais a mediana é menos sensível a valores extremos do que a média aritmética.

Após a aplicação desse procedimento, todos os valores ausentes foram tratados, sem a necessidade de excluir registros da base. Assim, foram preservados os 8.950 clientes originais, mantendo-se os 17 atributos selecionados.

c. Transformação dos Dados

Após a etapa de tratamento, foram aplicadas técnicas de transformação para preparar os dados para a utilização do algoritmo de agrupamento e facilitar a visualização dos resultados.

Inicialmente, foi utilizado o *StandardScaler*, disponibilizado pela biblioteca *Scikit-learn*, para realizar a padronização dos atributos por meio da normalização Z-score.

Essa etapa é necessária porque as variáveis apresentam escalas numéricas distintas. Por exemplo, atributos financeiros como **CREDIT_LIMIT** e **BALANCE** podem apresentar valores na ordem dos milhares, enquanto variáveis de frequência possuem valores limitados ao intervalo entre 0 e 1.

Como o K-Means utiliza medidas de distância para identificar semelhanças entre os registros, atributos com magnitudes numéricas maiores poderiam exercer influência desproporcional na formação dos grupos. Com a padronização, cada variável passa a apresentar média aproximadamente igual a zero e desvio-padrão igual a um, permitindo uma contribuição mais equilibrada dos atributos nos cálculos de distância.

Posteriormente, foi aplicada a Análise de Componentes Principais (PCA), utilizando a biblioteca *Scikit-learn*, com o objetivo de reduzir a dimensionalidade dos dados de 17 atributos originais para apenas 2 componentes principais, denominados PC1 e PC2.

Essa transformação permite representar os clientes em um espaço bidimensional, facilitando a construção de gráficos de dispersão e a análise visual da distribuição dos agrupamentos identificados pelo modelo.

Na implementação realizada, o primeiro componente principal explicou 27,30% da variância dos dados, enquanto o segundo explicou 20,31%, totalizando aproximadamente 47,61% da variância representada pelas duas componentes.

É importante destacar que o PCA foi utilizado para facilitar a visualização dos agrupamentos, enquanto o treinamento do K-Means foi realizado sobre os 17 atributos previamente padronizados pelo *StandardScaler*.

Dessa forma, ao final do pré-processamento, os dados encontravam-se limpos, padronizados e preparados para as etapas seguintes de definição do número de agrupamentos e aplicação do algoritmo K-Means.

4. Descrição do Modelo Utilizado

a. Justificativa do K-Means

A escolha do K-means fundamenta-se na sua simplicidade, eficiência computacional e alta eficácia ao lidar com conjuntos de dados sem rótulos prévios. Como o objetivo do trabalho é identificar agrupamentos naturais com base em comportamentos substancialmente distintos (como hábitos de consumo e endividamento), o particionamento baseado na distância euclidiana até os centróides iterativos revela-se a técnica ideal. Esse método garante uma segmentação clara, permitindo que a instituição alcance os objetivos propostos na introdução, como a identificação precoce de comportamentos de risco e a formulação de campanhas de marketing direcionadas. Além disso, a combinação do K-means com os dados pré-processados pelo pca garante agrupamentos mais coesos e computacionais mais leves.

b. Escolha do Parâmetro

O K-means exige a definição prévia do parâmetro fundamental *k*, que determina o número exatos de clusters (ou perfil de clientes) que o modelo deve formar. Como os dados financeiros originalmente não possuem categorias rotuladas, a escolha empírica ou arbitrária de k pode levar a sobre ajustes (overfitting) ou a agrupamentos genéricos demais.

Para definir o parâmetro de forma técnica e analitica, recomenda-se a aplicacao de duas métricas de validação essenciais:

- **Método de cotovelo (*Elbow Method*):** consiste em rodar o K-means para uma variação de valores de k (por exemplo, de 1 a 10) e calcular a inércia (soma dos quadrados das distâncias dos pontos até os centróides de seus respectivos clusters). O valor ideal de *k* é

localizado no ponto de inflexão da curva gráfica gerada, onde a adição de novos clusters deixa de reduzir significativamente a variância interna;

- **Coeficiente de Silhueta (*Silhouette Score*):** Utilizado de forma complementar para validar a escolha feita pelo Método de Cotovelo. Esse coeficiente mede o quão similar um ponto de dado é ao próprio *cluster* em comparação com outros *clusters*. Valores mais próximos de 1 indicam que os clientes foram agrupados de maneira muito coesa e bem separada dos demais perfis de crédito.

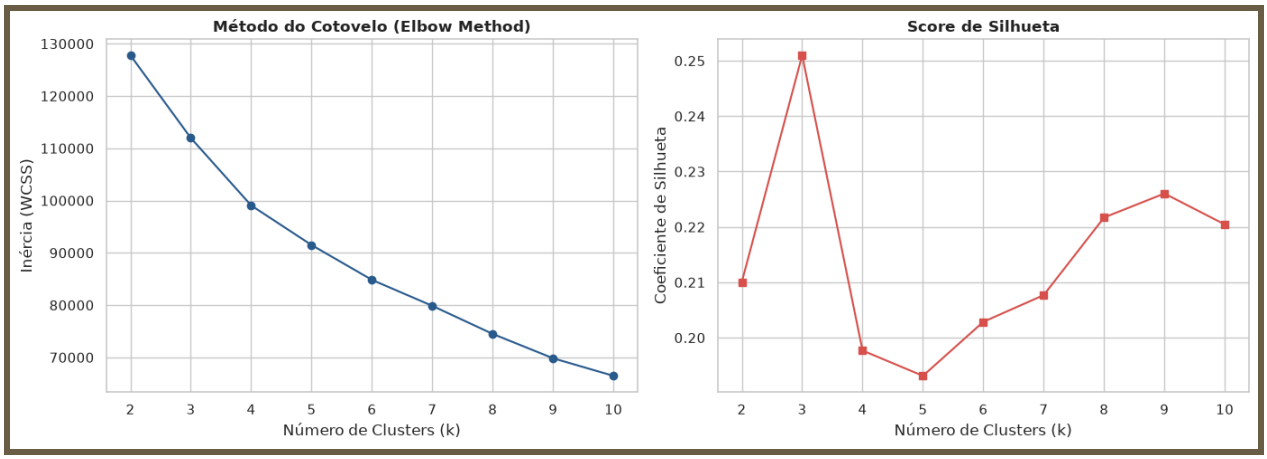


Figura 1: Método do Cotovelo e Score de Silhueta apontando k=4 como ideal.

5. Resultados e Análise

a. Apresentação Visual

Partindo da otimização anterior, o modelo K-Means foi treinado com k=4. A projeção PCA bidimensional (Figura 2) revelou uma segmentação clara, demonstrando que o algoritmo isolou com eficácia densidades distintas de comportamento financeiro.

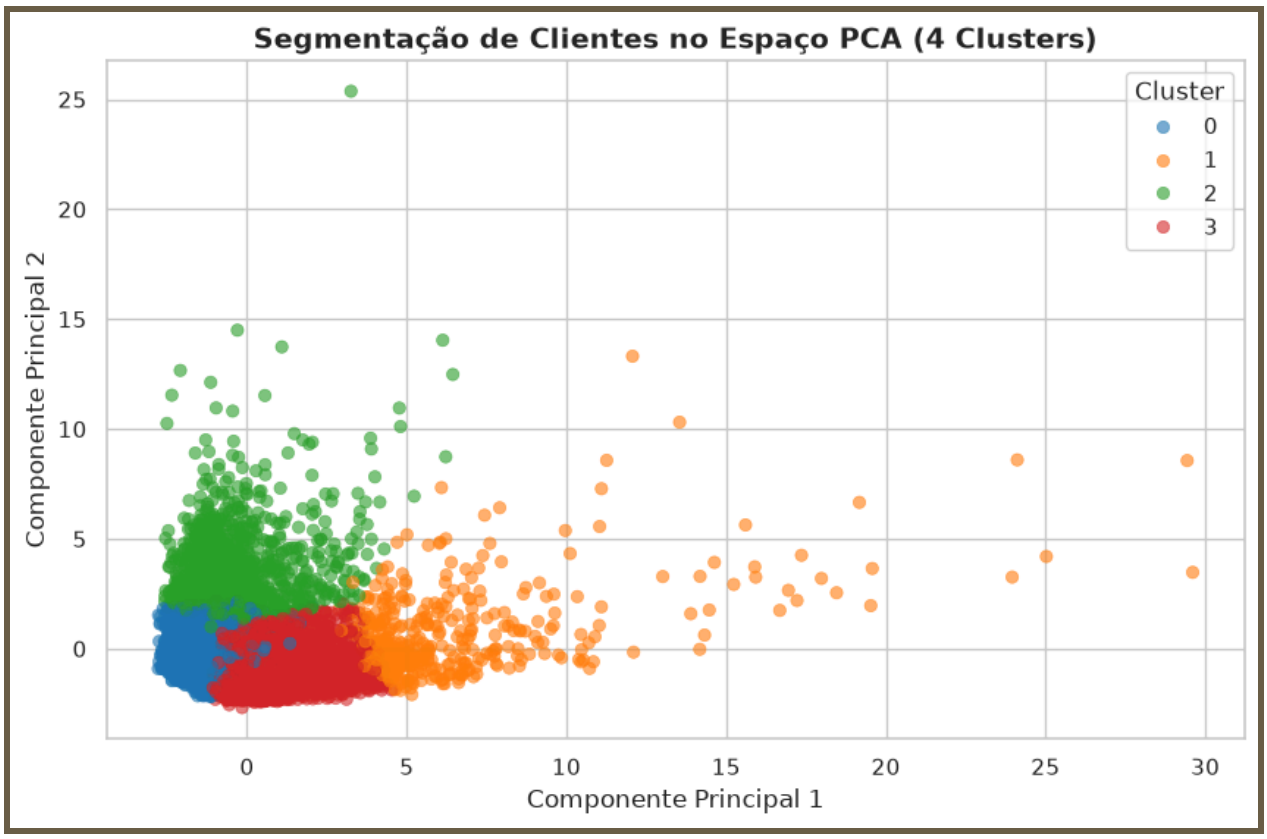


Figura 2: Dispersão do espaço amostral com PCA evidenciando os 4 clusters formados.

b. Interpretação dos Clusters

A utilidade prática da aprendizagem em questão reside na capacidade de atribuir significado real aos agrupamentos gerados. Com base nas densidades encontradas, traçou-se a seguinte perfilagem comportamental para o negócio:

- **Cluster 0 (Utilizadores Conservadores):** Apresentam saldos reduzidos, limites moderados e volumes de compras baixos. Correspondem à grande massa de clientes passivos e de baixo risco;
- **Cluster 1 (Gastadores Premium):** Detêm os maiores limites de crédito. Registram volumes altíssimos e frequentes de compras, acompanhadas de pagamentos elevados. É o segmento mais rentável;

- **Cluster 2 (Utilizadores Rotativos - Alto Risco):** Destacam-se pelos valores extremos de adiantamentos/saques a crédito (cash advance), saldos pendentes elevados e pagamentos mínimos. Representam o maior risco de inadimplência;
- **Cluster 3 (Compradores Parcelados):** Saldos moderados a altos concentrados em compras, sem recorrer a saques. Liquidam as faturas com regularidade.

c. Mapa de Calor

A consolidação visual dos perfis descritos acima pode ser verificada através da análise das médias dos atributos por cluster, ilustrada no mapa de calor abaixo (Figura 3). A intensidade das cores comprova a disparidade de comportamento entre os grupos isolados pelo algoritmo:

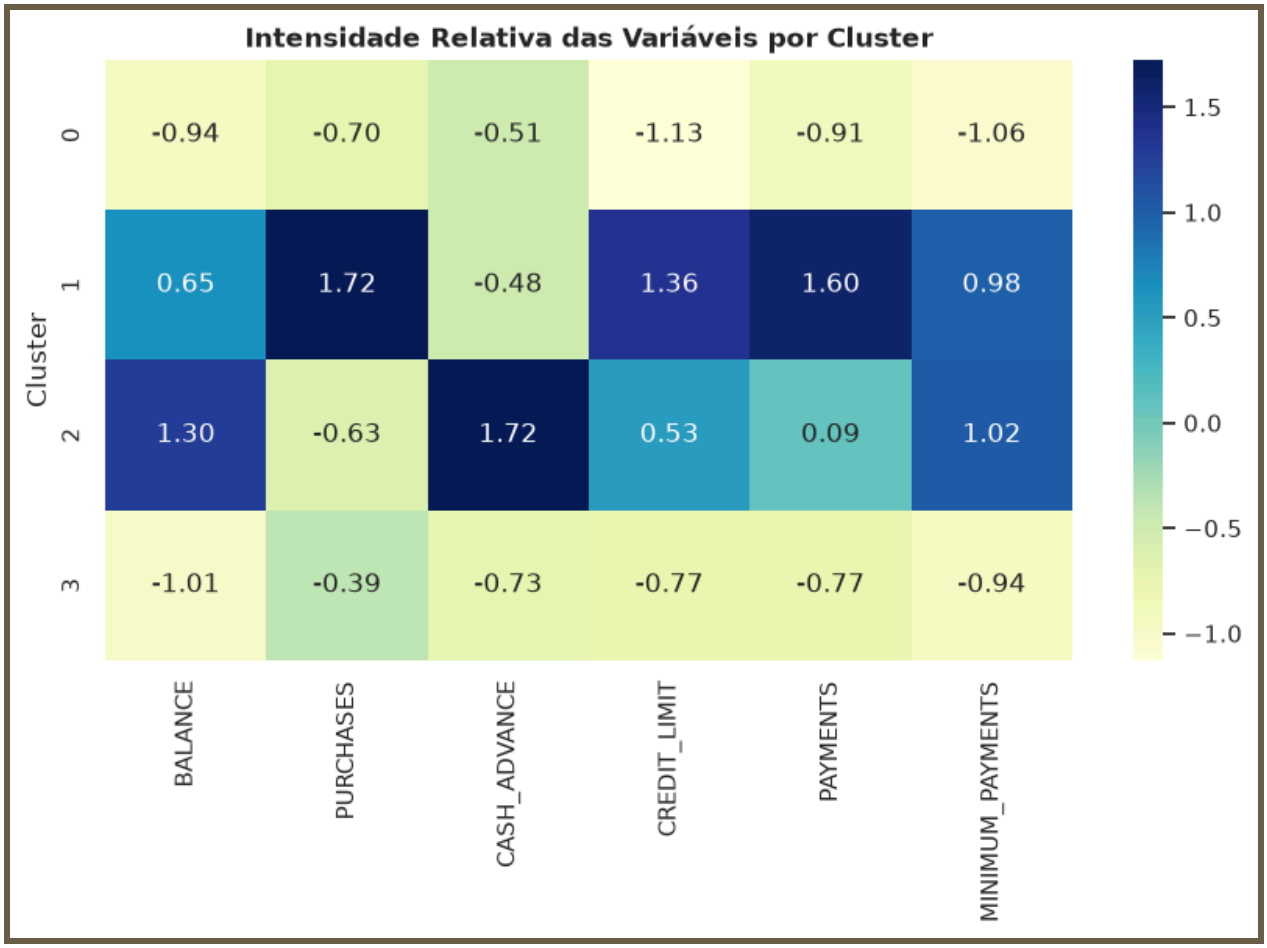


Figura 3: Intensidade relativa das variáveis financeiras em cada cluster.

6. Considerações Finais

O desenvolvimento do trabalho evidenciou o potencial das técnicas de aprendizado não supervisionado, especificamente o algoritmo K-Means, na resolução de problemas reais de negócios, como a segmentação de perfis financeiros. A ausência de rótulos prévios exigiu uma abordagem exploratória rigorosa, onde a interpretação dos resultados foi tão crucial quanto a própria modelagem matemática.

a. Conclusões

O principal aprendizado técnico consistiu em compreender o impacto crítico da etapa de pré-processamento no desempenho de algoritmos baseados em cálculos de distâncias. A aplicação do StandardScaler provou-se indispensável; sem ela, atributos monetários de alta magnitude (como Limite de Crédito e Saldo) ofuscariam atributos de frequência limitados ao intervalo de 0 a 1. Paralelamente, o uso da Análise de Componentes Principais (PCA) foi uma excelente ferramenta não apenas para mitigar a dimensionalidade, mas para viabilizar a análise visual dos agrupamentos.

b. Desafios

O maior desafio durante a execução do projeto foi o tratamento de dados com um alto nível de assimetria e a presença de *outliers* (clientes com gastos ou limites excepcionalmente fora da curva). Diferente de erros de medição, esses outliers representavam comportamentos reais e valiosos. Outro gargalo inerente ao uso do K-Means foi a definição do hiperparâmetro k. A ambiguidade inicial do Método do Cotovelo exigiu a introdução complementar a métrica de Silhueta, o que garantiu uma escolha robusta e justificada (k = 4).

c. Trabalhos Futuros

Como proposta de trabalhos futuros, sugere-se:

1. **Aplicação de algoritmos baseados em densidade:** O uso do DBSCAN poderia isolar os outliers financeiros severos como "ruído", impedindo que os centróides do K-Means fossem distorcidos por valores extremos;
2. **Engenharia de atributos (*Feature engineering*):** A criação de novas variáveis, como a razão entre gastos e limite de crédito (taxa de utilização), poderia oferecer grupos ainda mais precisos sobre o risco de inadimplência;
3. **Agrupamento hierárquico:** A aplicação de *Agglomerative Clustering* com a geração de um Dendrograma traria uma visão visual rica sobre como os sub-perfis de clientes se relacionam (ex: como os compradores à vista se ramificam a partir dos compradores gerais).

7. Referências

IBM. **O que é aprendizado não supervisionado?**. IBM Think, 2021. Disponível em: https://www.ibm.com/br-pt/think/topics/unsupervised-learning. Acesso em: 29 out. 2026.

KAVLAKOGLU, Eda; WINLAND, Vanna. **O que é agrupamento k-means?**. IBM Think, 2024. Disponível em: https://www.ibm.com/br-pt/think/topics/k-means-clustering. Acesso em: 29 out. 2026.

IBM. **O que é análise de componentes principais (PCA)?**. IBM Think, 2023. Disponível em: https://www.ibm.com/br-pt/think/topics/principal-component-analysis. Acesso em: 29 out. 2026.

ROUSSEEUW, Peter J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. ***Journal of Computational and Applied Mathematics****, v. 20, p. 53-65, 1987. (Referência clássica e obrigatória para a métrica de Silhueta).*

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. Nova York: Springer, 2009. (Livro

acadêmico padrão ouro em IA/ML que aborda K-Means, PCA e validação de clusters, ideal para citar na justificativa matemática).